Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа №2
по дисциплине
«Методы машинного обучения»
на тему

«Обработка признаков»

Выполнил: Ван Пэй
Группа: ИУ5-21М

Москва — 2021 г.

1. Цель лабораторной работы

Изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.

2. Задание

- устранение пропусков в данных;
- кодирование категориальных признаков;
- нормализацию числовых признаков.

3. Ход выполнения работы

Подключим необходимые библиотеки и настроим отображение графиков

```
import numpy as np
import pandas as pd
```

```
import matplotlib as mpl
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import LabelEncoder,StandardScaler
from sklearn.impute import SimpleImputer
from sklearn.ensemble import RandomForestRegressor
import xgboost as xgb
```

Возьмём набор данных：

In [22]:
```
train_data = pd.read_csv('C:/Users/王沛/Desktop/train.csv',index_col=0)
test_sub = pd.read_csv('C:/Users/王沛/Desktop/sample_submission.csv',index_col=0

train_y = train_data['SalePrice']
train_data.drop(['SalePrice'],axis=1,inplace=True)

data = train_data
features = data.columns
sns.set_style('whitegrid')
```

Посмотрим на эти наборы данных:

```
data.dtypes
```

```
MSSubClass         int64
MSZoning          object
LotFrontage      float64
LotArea            int64
Street            object
                   ...
MiscVal            int64
MoSold             int64
YrSold             int64
SaleType          object
SaleCondition     object
Length: 79, dtype: object
```

```
data.head()
```

Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour
1	60	RL	65.0	8450	Pave	NaN	Reg	Lvl
2	20	RL	80.0	9600	Pave	NaN	Reg	Lvl
3	60	RL	68.0	11250	Pave	NaN	IR1	Lvl
4	70	RL	60.0	9550	Pave	NaN	IR1	Lvl
5	60	RL	84.0	14260	Pave	NaN	IR1	Lvl

5 rows × 79 columns

Функции:

```
def Na_rate(data):
    na_df = pd.DataFrame(columns=['feature_name','na_rate'])
    na_rate = []
    for i in data.columns:
        rate = data[i].isnull().sum()*1.0/len(data[i])
        na_rate.append(rate)

    na_df['feature_name'] = features
    na_df['na_rate'] = na_rate
    na_df = na_df[na_df['na_rate']!=0].sort_values(by='na_rate',ascending=False)
    print('miss_features_num',na_df.shape[0])
    return na_df
```

```
def Dis_features(data):
    cat_features = []
    num_features = []
    for i in data.columns:
        if data[i].dtype == 'object':
            cat_features.append(i)
        else:
            num_features.append(i)
    if 'Id' in num_features:
        num_features.remove('Id')
    print('Категориальные признаки: ',len(cat_features))
    print('Числовые признаки: ',len(num_features))

    return cat_features,num_features

def Fill_reason_missing(data,features):
    data1 = data.copy()
    for i in features:
        data1[i] = data1[i].fillna(-1)
        data1[i] = data1[i].map(lambda x:x if x==-1 else 1)
    return data1
```

```
def Fill_num_miss(data,col):
    data1 = data.copy()
    for i in col:
        data1[i] = SimpleImputer().fit_transform(data1[i].values.reshape(-1,1))
    return data1
def Fill_cat_miss(data,col):
    data1 = data.copy()
    for i in col:
        data1[i] = data1[i].fillna(data1[i].dropna().mode()[0])
    return data1
#кодирование категориальных признаков
def Cat_encoder(data,col):
    data1 = data.copy()
    for i in col:
        data1[i] = pd.factorize(data1[i])[0]
    return data1
#нормализацию числовых признаков
def Standard_num(data,col):
    data1 = data.copy()
    for i in col:
        data1[i] = StandardScaler().fit_transform(data1[i].values.reshape(-1,1))
    return data1
```

3.1. Обработка пропусков в данных

Проверить целевую переменную:

```
print('Отклонение: ',train_y.skew())
print('Эксцесс: ',train_y.kurt())
train_y.hist(bins=50)
plt.show()
```

```
Отклонение:  1.8828757597682129
Эксцесс:  6.536281860064529
```

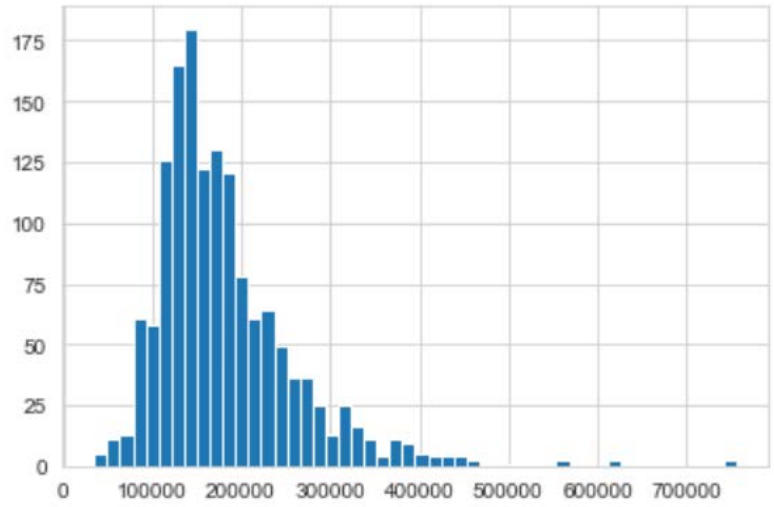


```
#Нормальное распределение смещено вправо
```

```
log_train_y = np.log(1+train_y)
print('Отклонение: ',log_train_y.skew())
print('Эксцесс: ',log_train_y.kurt())
log_train_y.hist(bins=50)
plt.show()
```

```
Отклонение:  0.12134661989685333
Эксцесс:  0.809519155707878
```

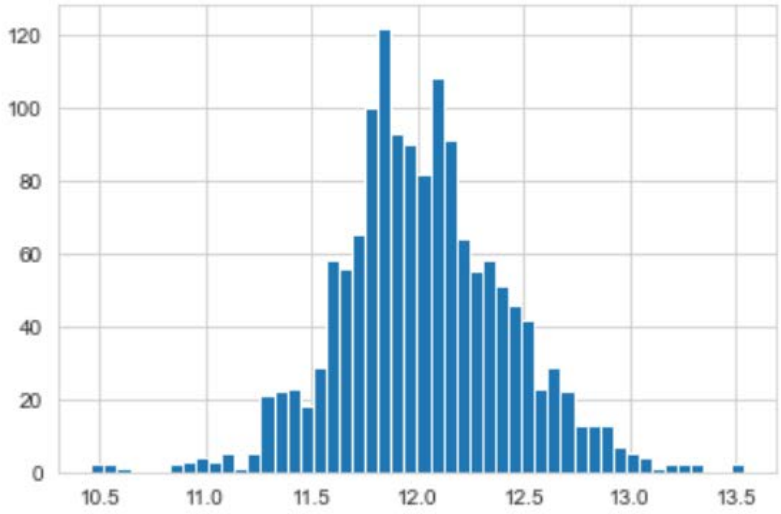

:
```
cat_all, num_all = Dis_features(data)
```

```
Категориальные признаки: 43
Числовые признаки: 36
```

```
na_train = Na_rate(train_data)
print(na_train)
```

```
miss_features_num 19
    feature_name   na_rate
71        PoolQC  0.995205
73   MiscFeature  0.963014
5          Alley  0.937671
72         Fence  0.807534
56   FireplaceQu  0.472603
2    LotFrontage  0.177397
57    GarageType  0.055479
58   GarageYrBlt  0.055479
59  GarageFinish  0.055479
62    GarageQual  0.055479
63    GarageCond  0.055479
31  BsmtExposure  0.026027
34  BsmtFinType2  0.026027
32  BsmtFinType1  0.025342
30      BsmtCond  0.025342
29      BsmtQual  0.025342
25    MasVnrArea  0.005479
24    MasVnrType  0.005479
41    Electrical  0.000685
```

```
na_all = Na_rate(data)
print(na_all)
miss_40_features = na_all[na_all['na_rate']>0.4]['feature_name'].values
```

```
    feature_name   na_rate
71        PoolQC  0.995205
73   MiscFeature  0.963014
5          Alley  0.937671
72         Fence  0.807534
56   FireplaceQu  0.472603
2    LotFrontage  0.177397
57    GarageType  0.055479
58   GarageYrBlt  0.055479
59  GarageFinish  0.055479
62    GarageQual  0.055479
63    GarageCond  0.055479
31  BsmtExposure  0.026027
34  BsmtFinType2  0.026027
32  BsmtFinType1  0.025342
30      BsmtCond  0.025342
29      BsmtQual  0.025342
25    MasVnrArea  0.005479
24    MasVnrType  0.005479
41    Electrical  0.000685
```

```
print('Train: ')
missing_data_train = train_data[na_train['feature_name'].values]
cat_miss_train, num_miss_train = Dis_features(missing_data_train)
print(num_miss_train)
```

```
Train:
Категориальные признаки:  16
Числовые признаки:  3
['LotFrontage', 'GarageYrBlt', 'MasVnrArea']
```

In [109]:
```
data['LotFrontage'] = SimpleImputer().fit_transform(data['LotFrontage'].values.r
for i in num_miss:
    data[i] = data[i].fillna(-1)


missing_data = data[na_all2['feature_name'].values]
Dis_features(missing_data)
```

```
Категориальные признаки: 16
Числовые признаки: 0
```

Out[109]:
```
(['PoolQC',
  'MiscFeature',
  'Alley',
  'Fence',
  'FireplaceQu',
  'GarageType',
  'GarageFinish',
  'GarageQual',
  'GarageCond',
  'BsmtExposure',
  'BsmtFinType2',
  'BsmtQual',
  'BsmtCond',
  'BsmtFinType1',
  'MasVnrType',
  'Electrical'],
 [])
```

```
fill_cat = na_all2[na_all2['na_rate']<0.02]['feature_name'].values
print(data['MasVnrType'].value_counts())
print('==========')
print(fill_cat)
data = Fill_cat_miss(data,fill_cat)
na_all3 = Na_rate(data)
print('==========')
print(na_all3)
```

```
None       864
BrkFace    445
Stone      128
BrkCmn      15
Name: MasVnrType, dtype: int64
==========
['MasVnrType' 'Electrical']
miss_features_num 14
==========
    feature_name   na_rate
71        PoolQC  0.995205
73   MiscFeature  0.963014
5          Alley  0.937671
72         Fence  0.807534
56   FireplaceQu  0.472603
57    GarageType  0.055479
59  GarageFinish  0.055479
62    GarageQual  0.055479
63    GarageCond  0.055479
31  BsmtExposure  0.026027
34  BsmtFinType2  0.026027
29      BsmtQual  0.025342
30      BsmtCond  0.025342
32  BsmtFinType1  0.025342
```

3.2. Кодирование категориальных признаков

```
print('cat: ',cat_all)
print('='*50)
print('num:',num_all)
data = Cat_encoder(data,cat_all)
```

```
cat:  ['MSZoning', 'Street', 'Alley', 'LotShape', 'LandContour', 'Utilities',
'LotConfig', 'LandSlope', 'Neighborhood', 'Condition1', 'Condition2', 'BldgTyp
e', 'HouseStyle', 'RoofStyle', 'RoofMatl', 'Exterior1st', 'Exterior2nd', 'MasV
nrType', 'ExterQual', 'ExterCond', 'Foundation', 'BsmtQual', 'BsmtCond', 'Bsmt
Exposure', 'BsmtFinType1', 'BsmtFinType2', 'Heating', 'HeatingQC', 'CentralAi
r', 'Electrical', 'KitchenQual', 'Functional', 'FireplaceQu', 'GarageType', 'G
arageFinish', 'GarageQual', 'GarageCond', 'PavedDrive', 'PoolQC', 'Fence', 'Mi
scFeature', 'SaleType', 'SaleCondition']
==================================================
num: ['MSSubClass', 'LotFrontage', 'LotArea', 'OverallQual', 'OverallCond', 'Y
earBuilt', 'YearRemodAdd', 'MasVnrArea', 'BsmtFinSF1', 'BsmtFinSF2', 'BsmtUnfS
F', 'TotalBsmtSF', '1stFlrSF', '2ndFlrSF', 'LowQualFinSF', 'GrLivArea', 'BsmtF
ullBath', 'BsmtHalfBath', 'FullBath', 'HalfBath', 'BedroomAbvGr', 'KitchenAbvG
r', 'TotRmsAbvGrd', 'Fireplaces', 'GarageYrBlt', 'GarageCars', 'GarageArea',
'WoodDeckSF', 'OpenPorchSF', 'EnclosedPorch', '3SsnPorch', 'ScreenPorch', 'Poo
lArea', 'MiscVal', 'MoSold', 'YrSold']
```

```
Na_rate(data)
```

```
miss_features_num 0
```

feature_name	na_rate

Нормализацию числовых признаков

```
data = Standard_num(data,num_all)
```

3.3. Нормализацию числовых признаков.

```
data = Standard_num(data,num_all)
```

```
for i in cat_all:
    length = len(set(data[i].values))
    print(i,length)
```

```
MSZoning 5
Street 2
Alley 3
LotShape 4
LandContour 4
Utilities 2
LotConfig 5
LandSlope 3
Neighborhood 25
Condition1 9
Condition2 8
BldgType 5
HouseStyle 8
RoofStyle 6
RoofMatl 8
Exterior1st 15
Exterior2nd 16
MasVnrType 4
ExterQual 4
ExterCond 5
Foundation 6
BsmtQual 5
BsmtCond 5
BsmtExposure 5
BsmtFinType1 7
BsmtFinType2 7
Heating 6
HeatingQC 5
CentralAir 2
Electrical 5
KitchenQual 4
Functional 7
FireplaceQu 6
GarageType 7
GarageFinish 4
GarageQual 6
GarageCond 6
```

```
PavedDrive 3
PoolQC 4
Fence 5
MiscFeature 5
SaleType 9
SaleCondition 6
```

Список литературы

[1] Гапанюк Ю. Е. Лабораторная работа «Разведочный анализ данных. Исследование и визуализация данных» [Электронный ресурс]

[2] Wes McKinney «Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython»